

OTIMIZAÇÃO NUMÉRICA

ALGORITMO DE NELDER-MEAD

Busca Direta Multidimensional sem Derivadas


Aluno: Romulo de Aguiar Beninca

Professor: Prof. Dr. Carlos Alberto Bavastri

UFPR - Engenharia Mecânica

INTRODUÇÃO E ORIGEM HISTÓRICA

- **Histórico:** Proposto por John Nelder e Roger Mead em 1965.
- **Método:** Busca direta heurística que não depende de gradientes ou derivadas.
- **Diferencial:** Diferente do Simplex Linear, o Nelder-Mead deforma o poliedro para se adaptar à topologia da função.
- **Aplicações:** Ideal para funções "caixa-preta" ou ruidosas onde o cálculo da derivada é caro.




John A. Nelder (1924–2010)

MÉTODO

A ideia central: em vez de usar derivadas para saber "para onde descer", o método mantém um **triângulo de pontos** (o *simplex*) sobre a superfície e, a cada passo, **joga fora o pior vértice**, criando um novo ponto melhor no lugar. Repetindo isso, o triângulo **rola, estica e encolhe** até cercar o mínimo.

- É um método **heurístico de busca direta**: decide tudo apenas **comparando valores** de $f(x)$ — nunca calcula gradientes.
- O **Simplex** tem $n + 1$ vértices em R^n (triângulo em 2D, tetraedro em 3D).
- Ideal quando a derivada é **indisponível, cara ou ruidosa** — ex.: f vinda de simulação ou experimento (função "caixa-preta").

A ESTRUTURA – O SIMPLEX



GEOMETRIA DO SIMPLEX


Um *simplex* em um espaço de n dimensões é um poliedro com $n+1$ vértices:

- ▲ 2D: um triângulo (3 pontos).
- ◆ 3D: um tetraedro (4 pontos).

O algoritmo mantém esses pontos e "caminha" ou "encolhe" o simplex em direção ao valor mínimo da função através de iterações sucessivas.

A IDEIA EM UMA IMAGEM

As elipses são as **curvas de nível** de f (o "fundo do vale" é o ponto central).
O simplex parte longe e, eliminando sempre o pior vértice, **caminha passo a passo até o mínimo**:



vermelho = posição inicial → azul = simplex caminhando → verde = chegou ao mínimo

COMO O SIMPLEX SE ORGANIZA

Antes de cada movimento, os vértices são **ordenados** do melhor (menor f) ao pior (maior f):

$$f(x_1) \leq f(x_2) \leq \dots \leq f(x_{n+1})$$

$$x_1 = \text{Melhor (B)} \cdot x_n = \text{2º pior (G)} \cdot x_{n+1} = \text{Pior (W)}$$


É sempre o **Pior (W)** que tentamos eliminar — todos os movimentos dos próximos slides partem dele.

O PIVÔ: CENTROIDE (C)

Antes de qualquer movimento, calcula-se o **centro de massa** dos vértices — mas **excluindo o pior** (x_{n+1}). É em torno dele que o pior ponto será "espelhado".

$$c = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{média dos } n \text{ melhores vértices})$$

No exemplo abaixo (2D), o centroide c é o ponto médio da aresta entre o Melhor (B) e o Bom (G); o Pior (W) fica de fora.




1. REFLEXÃO (X_R)

É o movimento padrão. Espelha-se o pior vértice **através do centroide**, apostando que a direção oposta ao pior ponto leva "morro abaixo".

$$x_r = c + \alpha (c - x_{n+1}) \quad (\text{coeficiente de reflexão } \alpha = 1)$$

- Se x_r ficar **entre o melhor e o segundo pior** ($f(x_1) \leq f(x_r) < f(x_n)$): aceita-se x_r e segue-se para a próxima iteração.
- Se for **muito bom** ($f(x_r) < f(x_1)$) $\rightarrow$ tenta-se a **Expansão**. Se for **ruim** $\rightarrow$ tenta-se a **Contração**.




2. EXPANSÃO (X_E)

Se a reflexão bateu um novo recorde ($f(x_r) < f(x_1)$), a direção é promissora. O algoritmo **dá um passo ainda maior** no mesmo sentido, acelerando a descida.

$$x_e = c + \gamma (x_r - c) \quad (\text{coeficiente de expansão } \gamma = 2)$$

Compara-se então x_e com x_r : **fica o melhor dos dois** no lugar do pior vértice. É assim que o simplex "estica" e cobre mais terreno por iteração.



3. CONTRAÇÃO (X_c)


Se a reflexão foi **ruim**, provavelmente passamos do vale. Em vez de avançar, o simplex **recua em direção ao centroide**, sondando mais perto. Há duas variantes, conforme o x_r seja melhor ou pior que o pior vértice:

Externa (se $f(x_r) < f(x_{n+1})$): $x_c = c + \beta (x_r - c)$

Interna (se $f(x_r) \geq f(x_{n+1})$): $x_c = c + \beta (x_{n+1} - c)$

(coeficiente de contração $\beta = 0.5$)

Se nem a contração melhorar o pior vértice, recorre-se ao **encolhimento (shrink)** — visto no próximo slide.



4. ENCOLHIMENTO (SHRINK)

É o último recurso, usado quando **nenhum movimento anterior funcionou**. Em vez de mover só o pior ponto, **todos** os vértices são puxados em direção ao melhor (x_1), reduzindo o tamanho do simplex.

$$x_i \leftarrow x_1 + \sigma (x_i - x_1), \text{ para todo } i \neq 1 \quad (\text{coeficiente } \sigma = 0.5)$$

- Acontece quando a função tem geometria difícil (vales curvos, estreitos).
- Garante a **convergência**: ao encolher, o simplex se concentra em torno da melhor região conhecida.
- É a operação mais "cara": exige reavaliar f em n vértices de uma vez.

FLUXO DE UMA ITERAÇÃO

Resumo da ordem em que as operações são tentadas:

1. **Ordenar** os vértices e calcular o centroide c .
2. **Refletir** $\rightarrow$ obter x_r .
3. Se x_r é o novo melhor $\rightarrow$ **Expandir** e ficar com o melhor entre x_e e x_r .
4. Se x_r é apenas razoável $\rightarrow$ **aceitar** x_r .
5. Se x_r é ruim $\rightarrow$ **Contrair** (interna ou externa).
6. Se a contração falhar $\rightarrow$ **Encolher** todo o simplex.

A cada iteração, exatamente **uma** dessas ações é executada, e o simplex se aproxima do mínimo.

EXEMPLO PRÁTICO DETALHADO

Minimizar: $f(x, y) = x^2 + y^2$ (Paraboloide)

Início: $x_1(1, 1)$, $x_2(1, 2)$, $x_3(2, 1)$

Valores: $f(x_1) = 2$ (Melhor), $f(x_2) = 5$ (Médio), $f(x_3) = 5$ (Pior).

Passo	Cálculo	Resultado	Ação
1. Centroide	$c = (x_1 + x_2)/2$	$c = (1, 1.5)$	Pivô entre B e G
2. Reflexão	$x_r = c + 1(c - x_3)$	$x_r = (0, 2)$	$f(x_r) = 4$
3. Avaliação	$f(x_r) < f(x_2)?$	$4 < 5$ (Sim!)	Substituir x_3 por x_r

CRITÉRIOS DE PARADA

O algoritmo para quando o simplex "encolheu" o bastante — ou seja, todos os vértices têm valores de f quase iguais. Mede-se isso pelo **desvio padrão** dos valores no simplex:

$$\sqrt{\frac{1}{n+1} \sum_{i=1}^{n+1} [f(x_i) - \bar{f}]^2} < \epsilon \quad (\bar{f} = \text{média dos } f(x_i))$$

- Tolerância ϵ tipicamente 10^{-6} a 10^{-8} — quanto menor, mais preciso e mais lento.
- Também se encerra ao atingir um **número máximo de iterações** (proteção contra não-convergência).
- Alternativa comum: parar quando o **tamanho do simplex** (maior aresta) fica abaixo de ϵ

VANTAGENS E DESVANTAGENS

✓ VANTAGENS

- **Não usa derivadas** — funciona com funções não diferenciáveis, ruidosas ou "caixa-preta".
- **Simples de implementar** e de entender geometricamente.
- **Robusto** para problemas de baixa dimensão e bom para uma solução inicial rápida.
- Cada iteração é **barata**: poucas avaliações da função.

✗ DESVANTAGENS

- **Sem garantia de convergência** para o mínimo global — pode estagnar em mínimos locais.
- Perde eficiência em **alta dimensão** (acima de ~10 variáveis).
- Pode **colapsar/degenerar** o simplex e travar antes do ótimo.
- Convergência **mais lenta** que métodos que usam gradiente, quando este está disponível.

REFERÊNCIAS

- NELDER, J. A.; MEAD, R. *A Simplex Method for Function Minimization*. The Computer Journal, v. 7, n. 4, p. 308–313, 1965.
- BAVASTRI, C. A. *Notas de aula — Otimização Não Linear*. PPGEM, Universidade Federal do Paraná (UFPR).
- NOCEDAL, J.; WRIGHT, S. J. *Numerical Optimization*. 2. ed. New York: Springer, 2006.
- PRESS, W. H. et al. *Numerical Recipes: The Art of Scientific Computing*. 3. ed. Cambridge University Press, 2007. (cap. Downhill Simplex Method)
- Wikipedia. *Nelder–Mead method*. Disponível em: en.wikipedia.org/wiki/Nelder–Mead_method.
- Foto de John Nelder: Wikipedia, *John Nelder*. en.wikipedia.org/wiki/John_Nelder.

OBRIGADO!

Algoritmo de Nelder-Mead — Otimização Numérica

Romulo de Aguiar Beninca

Prof. Dr. Carlos Alberto Bavastri • UFPR — Engenharia Mecânica

Perguntas?